DW/BI Case Study

CITIBIKE

Version 0.4
CD_citibike

Azzam Sara, Dziekan Jiri Michael, Holzer Florentin,
Murhamer Serge Robert, Weber Benjamin

Date: 2026-03-16

FACHHOCHSCHULE TECHNIKUM WIEN

Change Log

Information: Enter the document history and the current state. Pay attention to the regular data maintenance. Use the above table "Legend" for the right description.

Version number	Date	Change	Person
0.1	09.03.2026	Business Case and Data Model	Weber Benjamin
0.2	10.03.2026	DFM aktualisiert & Dokument formatiert	Holzer Florentin
0.3	16.03.2026	Flow Diagram hinzugefügt	Dziekan Jiri
0.4	16.03.2026	Data Diagram hinzugefügt	Holzer Florentin

Table 1: Change log

Legend		
State	**W** **R** **F**	In work In review Released, freed version
Versioning	**0.1, 0.2** **1.0** **1.1, 1.2** **2.0**	Not approved version First released version Extended first version Second released version

Github-Link: https://github.com/floholzer/Citibike_Project

Table of Content

1 Business Case 4

1.1 Proposal for Improving the Business Case 4

1.1.1 Szenario 4

1.1.2 Stakeholder 4

1.1.3 Business Case 4

1.1.4 Kennzahlen & Metriken (Quantitative Analyse) 4

1.2 DFM 5

2 Data Model 6

2.1 Star Schema 6

3 ETL Concept 7

3.1 Data Map 7

3.2 Flow Diagram 8

4 ETL implementation 9

5 Data modelling and BI 9

5.1 Data modelling 9

6 BI Implementation 9

1 Business Case

1.1 Proposal for Improving the Business Case

1.1.1 Szenario

Datensatz: Citibike Usage (Nutzungsdaten des New Yorker Fahrradverleihsystems). Zusätzlicher Datensatz: Historische Wetterdaten open-meteo.com
Titel des Use Cases: Einfluss der Wetterbedingungen auf Citibike-Usage und Conversion (Casual to Member)
Ausrichtung: Verknüpfung von CitiBike-Fahrtdaten mit Wetterdaten um zu analysieren, wie Wetterbedingungen die Nutzungshäufigkeit und Conversion beeinflussen.

1.1.2 Stakeholder

Primärer Stakeholder: Operatives Management von CitiBike

1.1.3 Business Case

Current Approach (Aktuelle Situation): Die operative Steuerung des Bike-Sharing-Systems basiert primär auf historischen Fahrtdaten und Erfahrungswerten. Externe Einflussfaktoren – insbesondere das Wetter – werden bislang nicht systematisch in die Analyse der Nutzung einbezogen. Dadurch fehlen fundierte Erkenntnisse darüber, wie sich Temperatur und Niederschlag konkret auf Nachfrage, Stationsauslastung und Nutzersegmente auswirken.
Future Approach (Geplanter Ansatz): Entwicklung eines BI-Dashboards, das Fahrtdaten multidimensional analysiert und mit historischen Wetterdaten (z. B. Temperatur, Niederschlag) verknüpft. Ziel ist es, Transparenz über wetterbedingte Nutzungsmuster zu schaffen, besonders in Bezug auf Unterschiede zwischen Member- und Casual-Nutzern. Die gewonnenen Erkenntnisse dienen als Entscheidungsgrundlage für eine datenbasierte operative Steuerung und sollen folgende Leitfragen beantworten:
Wie verändert sich die Anzahl und Dauer der Fahrten bei unterschiedlichen Wetterbedingungen (Temperatur, Regen, Wind)?
Welche Stationen oder Stadtbereiche reagieren besonders stark auf Wetterveränderungen?
Wie viele Gelegenheitsnutzer schließen pro Jahr ein Abo ab?

Scope Statement (Geltungsbereich):
In scope: Trip-Daten (Startzeit, Dauer), Start- und End-Stationen (inkl. Geokoordinaten für Map-Visualisierung), User-Typen (Casual/Member) sowie die Integration externer, historischer Wetterdaten (Tageshöchsttemperatur, Niederschlag).
Out of scope: operative Wartungsdaten der Fahrräder, Rebalancing-Logistik sowie die detaillierte Analyse von Einzelkosten pro Ride

1.1.4 Kennzahlen & Metriken (Quantitative Analyse)

Um den Erfolg der BI-Initiative messbar zu machen, werden folgende Performance Indikatoren zur Bewertung des aktuellen Zustandes und der zukünftigen Verbesserung herangezogen:
Total Rides pro Wetterkategorie
Average Ride Duration je Wetterlage
Weather-Sensitivity-Score: Prozentuale Veränderung des Fahrtenvolumens und Fahrtendauer pro Station bei Regen vs. Sonnenschein.
Conversion-Rate (Casual to Member): Der prozentuale Anteil der Gelegenheitsnutzer.

1.2 DFM

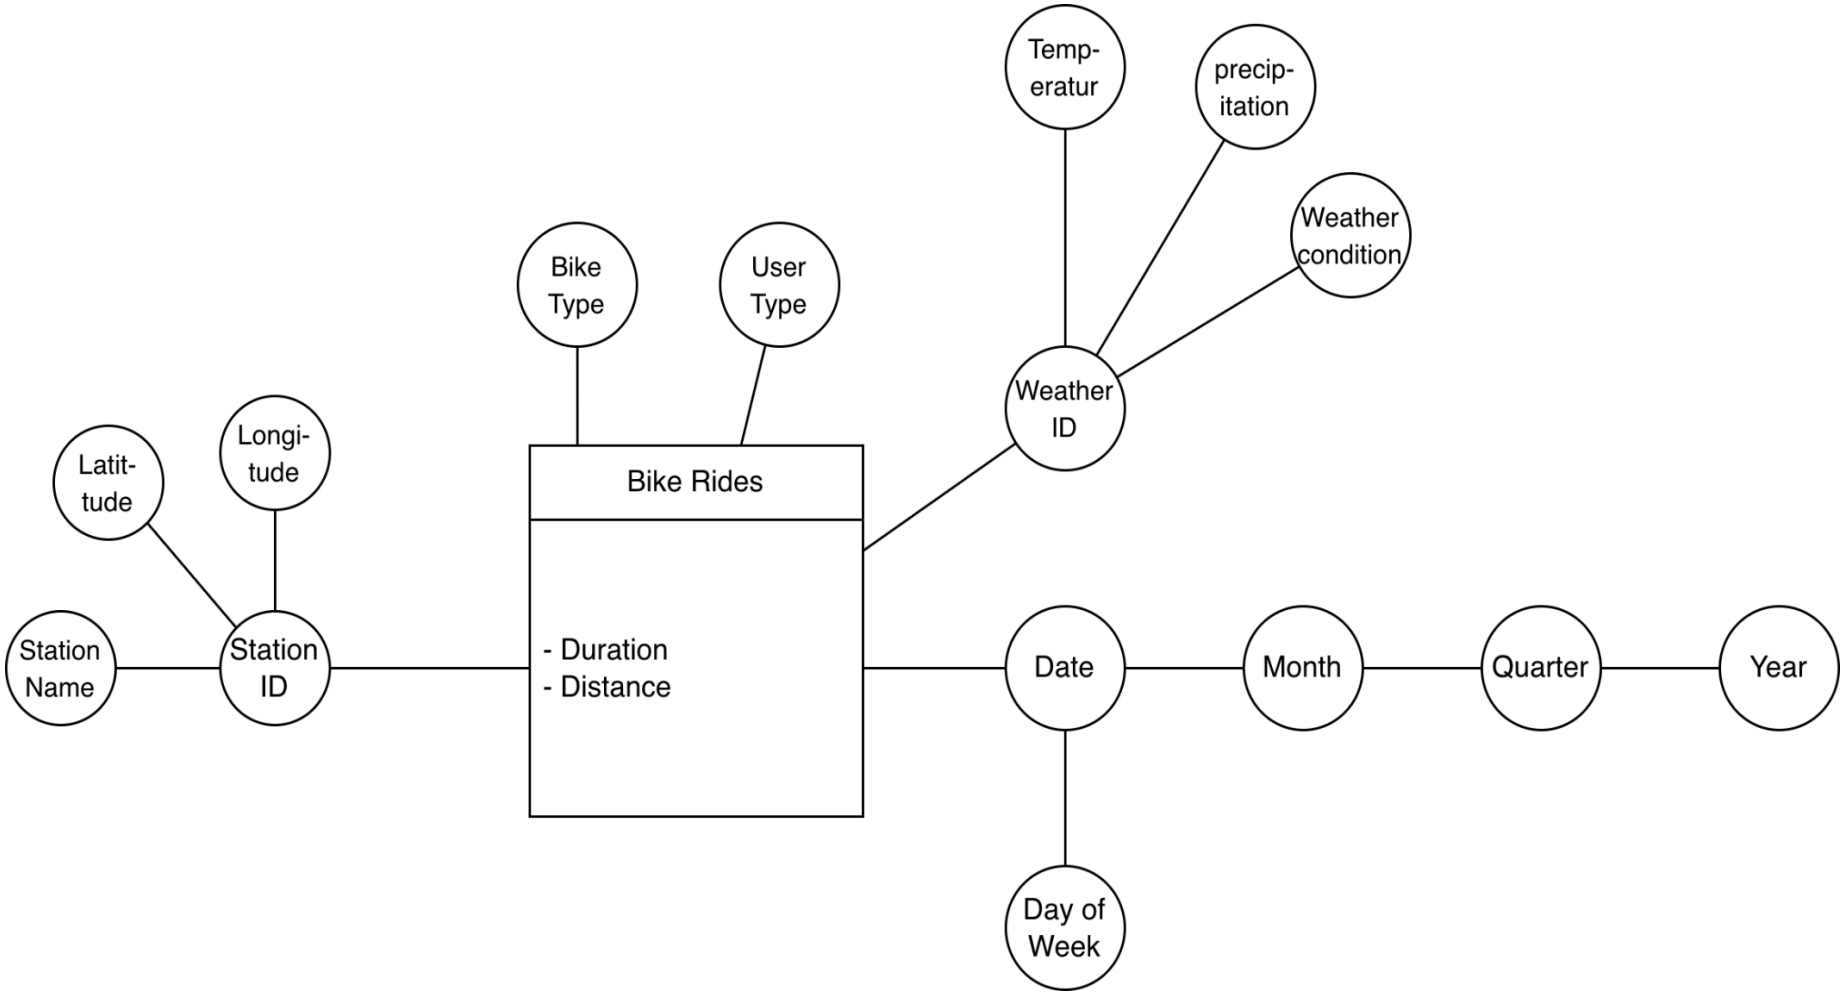

Abbildung 1 - DFM

2 Data Model

2.1 Star Schema

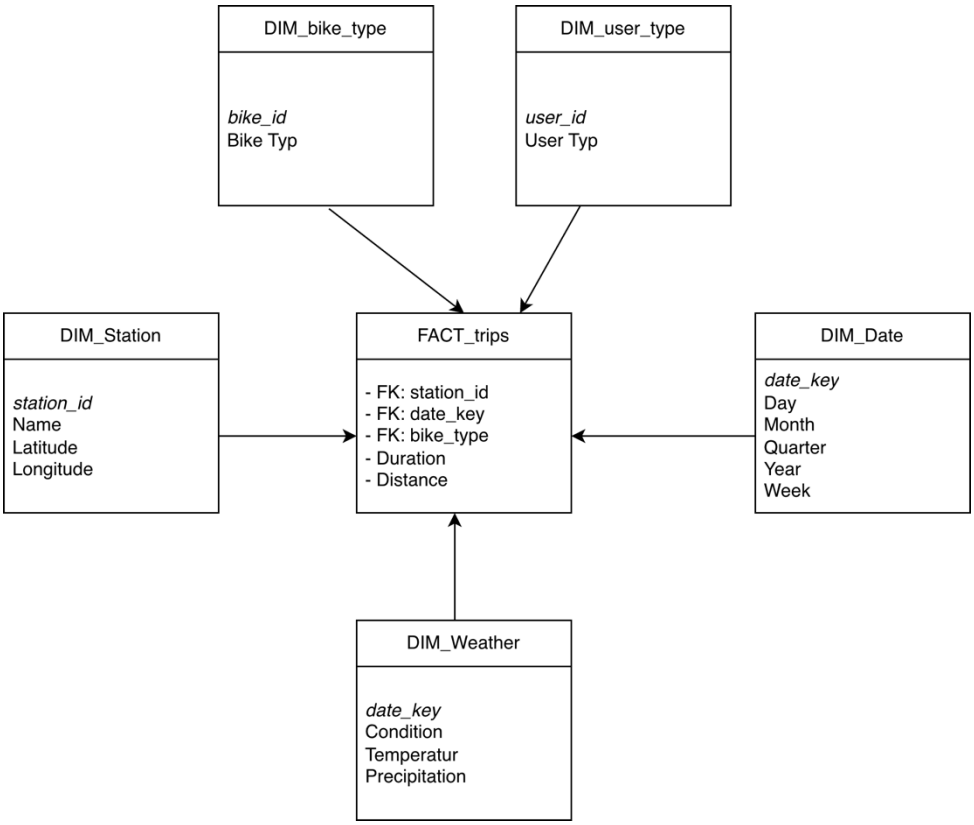

Abbildung 2 – Star Schema

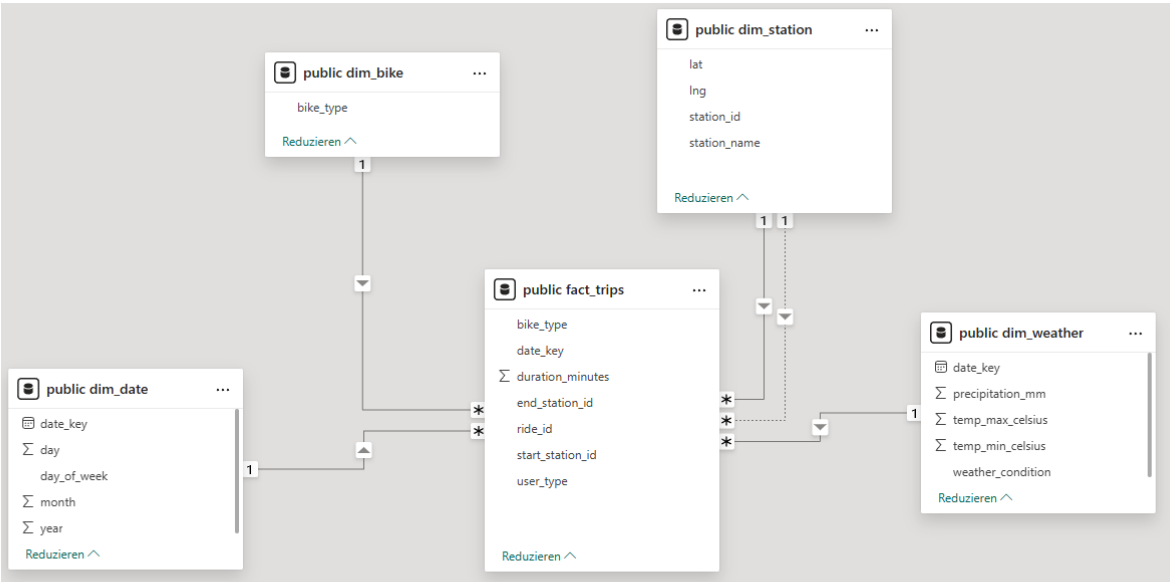

Abbildung 3 – Star Schema (PBI)

3 ETL Concept

3.1 Data Map

Target					Source				Transformation
Table Name	**Column Name**	**Data Type**	**Table Type**	**SCD Type**	**Database Name**	**Table Name**	**Column Name**	**Data Type**	
fact_trips	ride_id	VARCHAR	Fact	N/A	citibike_dwh	staging_citibike_trips	ride_id	VARCHAR	Direct mapping - Primary Key (Natural Key)
fact_trips	date_key	DATE	Fact	N/A	citibike_dwh	staging_citibike_trips	started_at	TIMESTAMP	CAST(started_at AS TIMESTAMP)::DATE - FK to dim_date.date_key
fact_trips	start_station_id	VARCHAR	Fact	N/A	citibike_dwh	staging_citibike_trips	start_station_id	VARCHAR	Direct mapping - FK to dim_station.station_id
fact_trips	end_station_id	VARCHAR	Fact	N/A	citibike_dwh	staging_citibike_trips	end_station_id	VARCHAR	Direct mapping - FK to dim_station.station_id
fact_trips	bike_type	VARCHAR	Fact	N/A	citibike_dwh	staging_citibike_trips	rideable_type	VARCHAR	rideable_type AS bike_type - FK to dim_bike.bike_type
fact_trips	user_type	VARCHAR	Fact	N/A	citibike_dwh	staging_citibike_trips	member_casual	VARCHAR	member_casual AS user_type - Degenerate Dimension (embedded)
fact_trips	duration_minutes	NUMERIC(10,2)	Fact	N/A	citibike_dwh	staging_citibike_trips	started_at, ended_at	TIMESTAMP	ROUND((EXTRACT(EPOCH FROM (ended_at - started_at)) / 60)::NUMERIC, 2)
dim_station	station_id	VARCHAR	Dimension	1	citibike_dwh	staging_citibike_trips	start_station_id, end_station_id	VARCHAR	UNION of start/end stations, GROUP BY station_id - Natural Key
dim_station	station_name	VARCHAR	Dimension	1	citibike_dwh	staging_citibike_trips	start_station_name, end_station_name	VARCHAR	MAX(station_name) - handles GPS variations
dim_station	lat	NUMERIC	Dimension	1	citibike_dwh	staging_citibike_trips	start_lat, end_lat	NUMERIC	MAX(lat) - stabilizes GPS coordinates
dim_station	lng	NUMERIC	Dimension	1	citibike_dwh	staging_citibike_trips	start_lng, end_lng	NUMERIC	MAX(lng) - stabilizes GPS coordinates
dim_date	date_key	DATE	Dimension	1	citibike_dwh	staging_citibike_trips	started_at, ended_at	TIMESTAMP	CAST(started_at AS TIMESTAMP)::DATE UNION CAST(ended_at AS TIMESTAMP)::DATE
dim_date	year	INTEGER	Dimension	1	citibike_dwh	staging_citibike_trips	started_at, ended_at	TIMESTAMP	EXTRACT(YEAR FROM date_val)
dim_date	month	INTEGER	Dimension	1	citibike_dwh	staging_citibike_trips	started_at, ended_at	TIMESTAMP	EXTRACT(MONTH FROM date_val)
dim_date	day	INTEGER	Dimension	1	citibike_dwh	staging_citibike_trips	started_at, ended_at	TIMESTAMP	EXTRACT(DAY FROM date_val)
dim_date	day_of_week	VARCHAR	Dimension	1	citibike_dwh	staging_citibike_trips	started_at, ended_at	TIMESTAMP	TRIM(TO_CHAR(date_val, 'Day'))
dim_bike	bike_type	VARCHAR	Dimension	1	citibike_dwh	staging_citibike_trips	rideable_type	VARCHAR	SELECT DISTINCT rideable_type AS bike_type
dim_weather	date_key	DATE	Dimension	1	citibike_dwh	staging_weather_historical	date_key	VARCHAR/DATE	CAST(date_key AS DATE) - Natural Key
dim_weather	temp_max_celsius	NUMERIC	Dimension	1	citibike_dwh	staging_weather_historical	temp_max_celsius	NUMERIC	Direct mapping from Open-Meteo API (temperature_2m_max)
dim_weather	temp_min_celsius	NUMERIC	Dimension	1	citibike_dwh	staging_weather_historical	temp_min_celsius	NUMERIC	Direct mapping from Open-Meteo API (temperature_2m_min)
dim_weather	precipitation_mm	NUMERIC	Dimension	1	citibike_dwh	staging_weather_historical	precipitation_mm	NUMERIC	Direct mapping from Open-Meteo API (precipitation_sum)
dim_weather	weather_condition	VARCHAR	Dimension	1	citibike_dwh	staging_weather_historical	precipitation_mm	NUMERIC	CASE WHEN precipitation_mm = 0 THEN '1_Trocken' WHEN precipitation_mm > 0 AND precipitation_mm <= 5 THEN '2_Leichter Regen (0-5mm)' ELSE '3_Starker Regen (>5mm)' END
dim_user_type	user_type	VARCHAR	Dimension	1	citibike_dwh	staging_citibike_trips	member_casual	VARCHAR	SELECT DISTINCT member_casual AS user_type - Natural Key

Abbildung 4 - Data Map

3.2 Flow Diagram

Der ETL-Prozess integriert CitiBike-Fahrtdaten aus CSV-Dateien mit historischen Wetterdaten aus der Open-Meteo API. In der Extract-Phase werden beide Quellen mit Python eingelesen. In der Transform-Phase werden Datumsformate vereinheitlicht, irrelevante Attribute entfernt, fehlende Werte geprüft, Dubletten gelöscht und ungültige Werte wie negative Fahrtdauern bereinigt. Anschließend werden die Wetterdaten über einen gemeinsamen date_key mit den Fahrtdaten verknüpft. In der Load-Phase werden die bereinigten und integrierten Daten in ein PostgreSQL Data Warehouse geladen, das als Star Schema mit Fact- und Dimensionstabellen modelliert ist. Die Umsetzung erfolgt mit Python, pandas, requests, SQLAlchemy und PostgreSQL. Zur Sicherstellung der Datenqualität werden Plausibilitätsprüfungen, Standardisierungen und Integritätskontrollen durchgeführt.

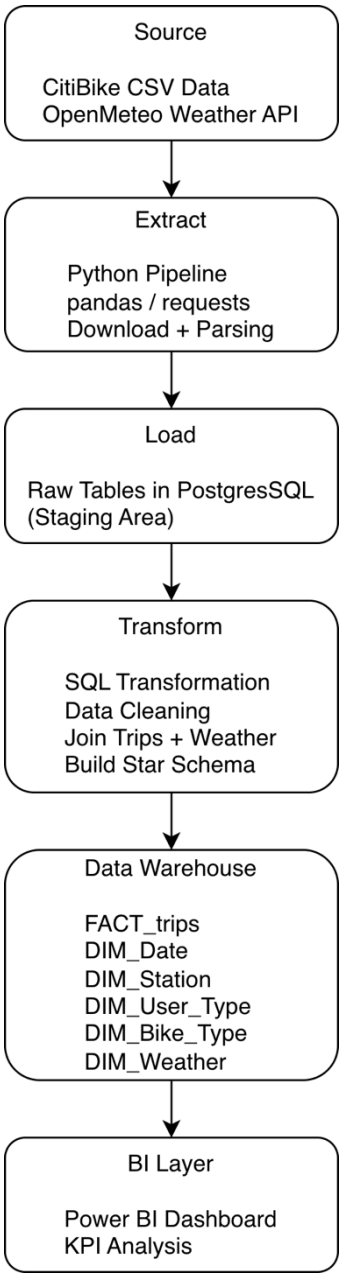

Abbildung 5 - Data Flow

4 ETL implementation

Insert screenshots and short descriptions of the implemented ETL process here.
Important: insert screenshots of the filled tables of your database after executing the process (e.g. table->select top x rows), for all dimension tables and the fact table.

5 Data modelling and BI

5.1 Data modelling

Insert a screenshot of data model modelled in PowerBI
Important: include screenshots for the configuration of all dimensions, including the created hierarchies if applicable.

6 BI Implementation

Present your BI implementation with a few screenshots, list your questions from section 2 and the answers to those questions. The screenshots should show that drill-down is supported.