DW/BI Case Study

CITIBIKE

Version 0.6
CD_citibike

Azzam Sara, Dziekan Jiri Michael, Holzer Florentin,
Murhamer Serge Robert, Weber Benjamin

Date: 2026-03-23

FACHHOCHSCHULE TECHNIKUM WIEN

Change Log

Information: Enter the document history and the current state. Pay attention to the regular data maintenance. Use the above table "Legend" for the right description.

Version number	Date	Change	Person
0.1	09.03.2026	Business Case and Data Model	Weber Benjamin
0.2	10.03.2026	DFM aktualisiert & Dokument formatiert	Holzer Florentin
0.3	16.03.2026	Flow Diagram hinzugefügt	Dziekan Jiri
0.4	16.03.2026	Data Diagram hinzugefügt	Holzer Florentin
0.5	17.03.2026	DataMap update	Holzer Florentin
0.6	23.03.2026	Kapitel 4: ETL implementation hinzugefügt	Dziekan Jiri

Table 1: Change log

Legend		
State	**W** **R** **F**	In work In review Released, freed version
Versioning	**0.1, 0.2** **1.0** **1.1, 1.2** **2.0**	Not approved version First released version Extended first version Second released version

Github-Link: https://github.com/floholzer/Citibike_Project

Table of Content

1 Business Case 4

1.1 Proposal for Improving the Business Case 4

1.1.1 Szenario 4

1.1.2 Stakeholder 4

1.1.3 Business Case 4

1.1.4 Kennzahlen & Metriken (Quantitative Analyse) 4

1.2 DFM 5

2 Data Model 6

2.1 Star Schema 6

3 ETL Concept 7

3.1 Data Map 7

3.2 Flow Diagram 8

4 ETL implementation 9

4.1 Beschreibug des ETL-Prozesses 9

4.1.1 Extract-Phase 9

4.1.2 Transform-Phase 9

4.1.3 Load-Phase 9

4.2 Ergebnis 10

4.2.1 Pipeline-Ausführung 10

4.2.2 SQL-Transformation 10

4.2.3 Nutzung der Daten in PowerBI 11

5 Data modelling and BI 15

5.1 Data modelling 15

6 BI Implementation 15

1 Business Case

1.1 Proposal for Improving the Business Case

1.1.1 Szenario

Datensatz: Citibike Usage (Nutzungsdaten des New Yorker Fahrradverleihsystems). Zusätzlicher Datensatz: Historische Wetterdaten open-meteo.com
Titel des Use Cases: Einfluss der Wetterbedingungen auf Citibike-Usage und Conversion (Casual to Member)
Ausrichtung: Verknüpfung von CitiBike-Fahrtdaten mit Wetterdaten um zu analysieren, wie Wetterbedingungen die Nutzungshäufigkeit und Conversion beeinflussen.

1.1.2 Stakeholder

Primärer Stakeholder: Operatives Management von CitiBike

1.1.3 Business Case

Current Approach (Aktuelle Situation): Die operative Steuerung des Bike-Sharing-Systems basiert primär auf historischen Fahrtdaten und Erfahrungswerten. Externe Einflussfaktoren – insbesondere das Wetter – werden bislang nicht systematisch in die Analyse der Nutzung einbezogen. Dadurch fehlen fundierte Erkenntnisse darüber, wie sich Temperatur und Niederschlag konkret auf Nachfrage, Stationsauslastung und Nutzersegmente auswirken.
Future Approach (Geplanter Ansatz): Entwicklung eines BI-Dashboards, das Fahrtdaten multidimensional analysiert und mit historischen Wetterdaten (z. B. Temperatur, Niederschlag) verknüpft. Ziel ist es, Transparenz über wetterbedingte Nutzungsmuster zu schaffen, besonders in Bezug auf Unterschiede zwischen Member- und Casual-Nutzern. Die gewonnenen Erkenntnisse dienen als Entscheidungsgrundlage für eine datenbasierte operative Steuerung und sollen folgende Leitfragen beantworten:
Wie verändert sich die Anzahl und Dauer der Fahrten bei unterschiedlichen Wetterbedingungen (Temperatur, Regen, Wind)?
Welche Stationen oder Stadtbereiche reagieren besonders stark auf Wetterveränderungen?
Wie viele Gelegenheitsnutzer schließen pro Jahr ein Abo ab?

Scope Statement (Geltungsbereich):
In scope: Trip-Daten (Startzeit, Dauer), Start- und End-Stationen (inkl. Geokoordinaten für Map-Visualisierung), User-Typen (Casual/Member) sowie die Integration externer, historischer Wetterdaten (Tageshöchsttemperatur, Niederschlag).
Out of scope: operative Wartungsdaten der Fahrräder, Rebalancing-Logistik sowie die detaillierte Analyse von Einzelkosten pro Ride

1.1.4 Kennzahlen & Metriken (Quantitative Analyse)

Um den Erfolg der BI-Initiative messbar zu machen, werden folgende Performance Indikatoren zur Bewertung des aktuellen Zustandes und der zukünftigen Verbesserung herangezogen:
Total Rides pro Wetterkategorie
Average Ride Duration je Wetterlage
Weather-Sensitivity-Score: Prozentuale Veränderung des Fahrtenvolumens und Fahrtendauer pro Station bei Regen vs. Sonnenschein.
Conversion-Rate (Casual to Member): Der prozentuale Anteil der Gelegenheitsnutzer.

1.2 DFM

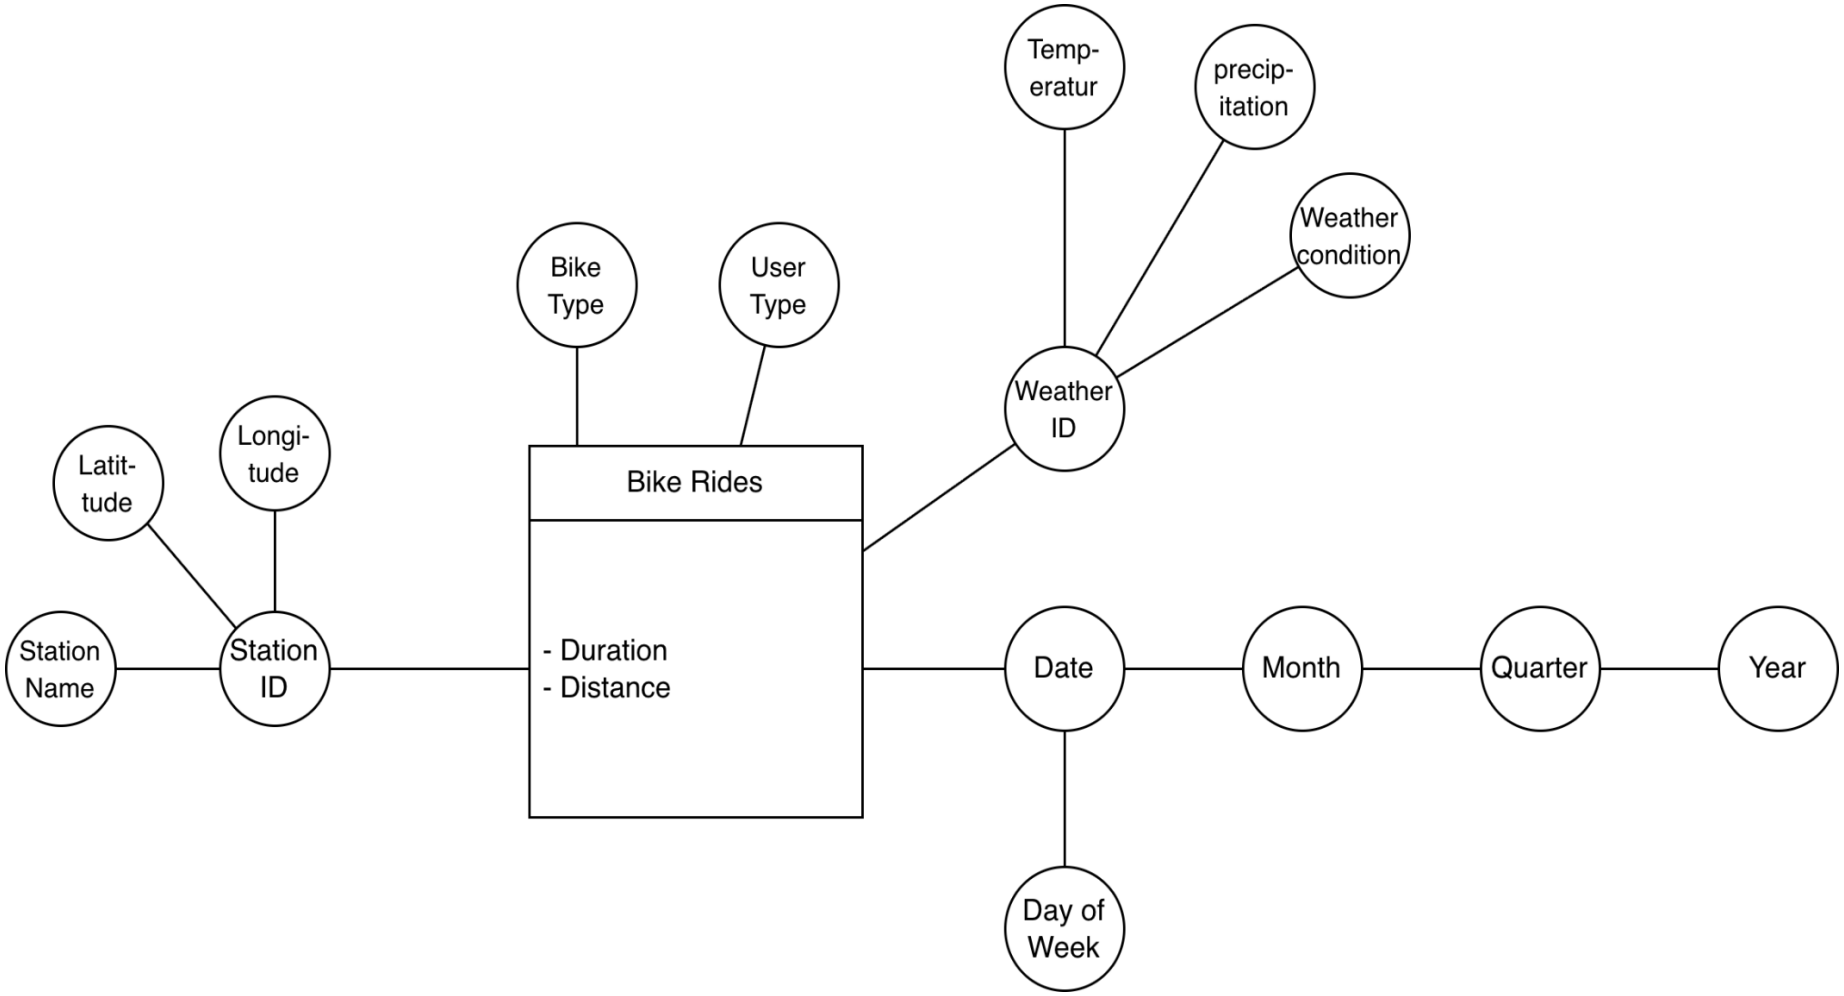

Abbildung 1 - DFM

2 Data Model

2.1 Star Schema

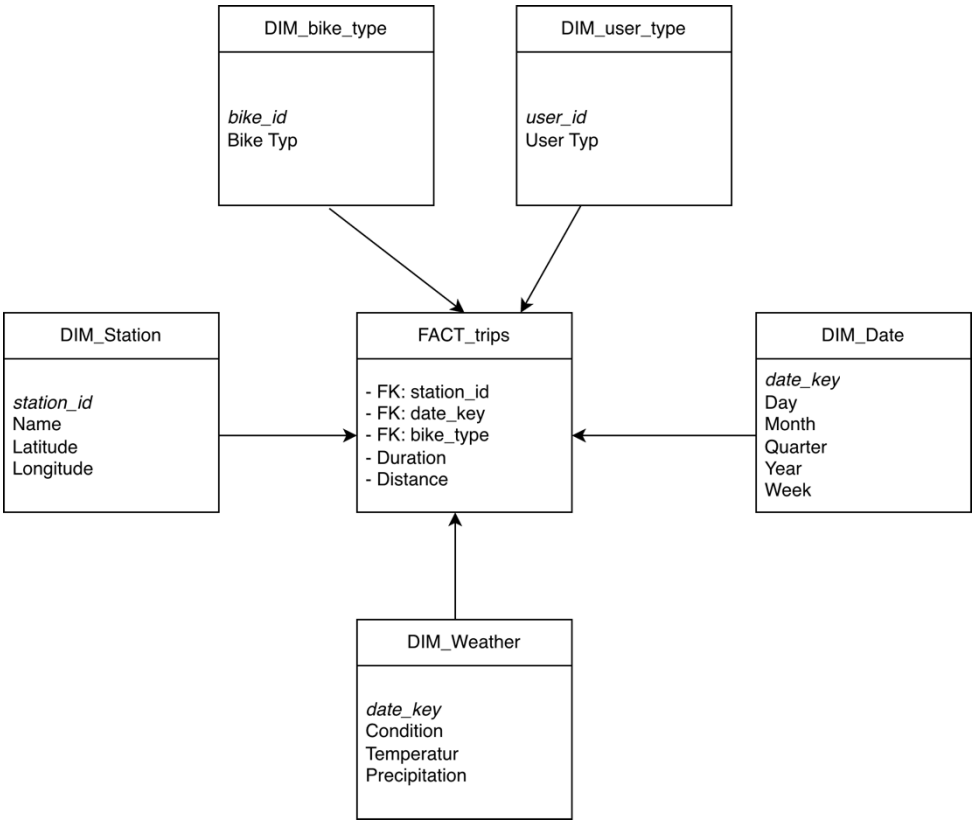

Abbildung 2 – Star Schema

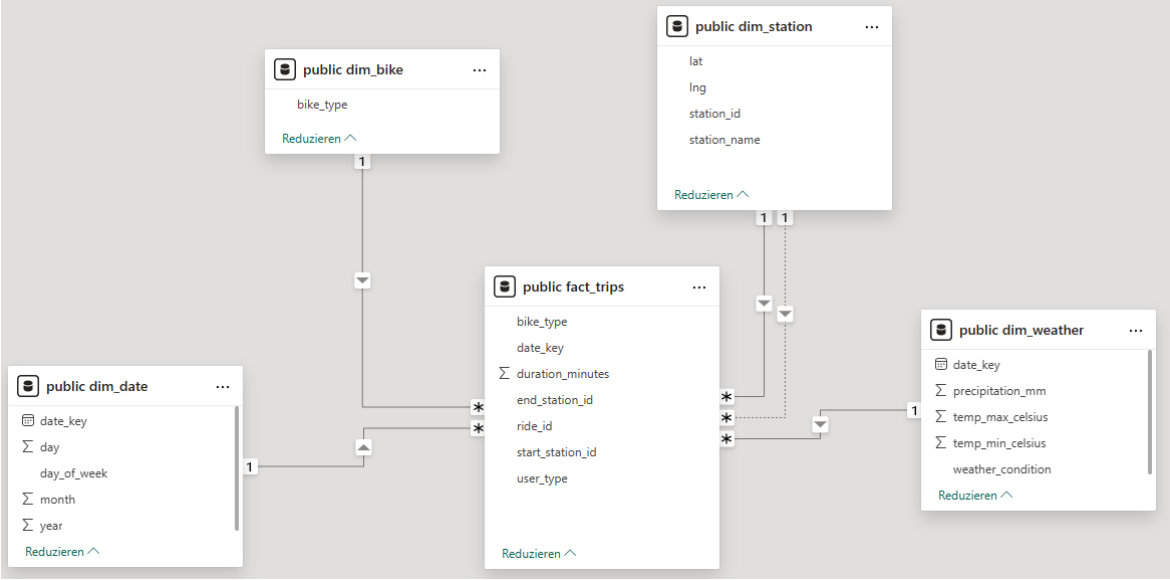

Abbildung 3 – Star Schema (PBI)

3 ETL Concept

3.1 Data Map

Target					Source				Transformation
Table Name	**Column Name**	**Data Type**	**Table Type**	**SCD Type**	**Database Name**	**Table Name**	**Column Name**	**Data Type**	
fact_trips	trip_sk	INTEGER	Fact	N/A	citibike_dwh	staging_citibike_trips	-	-	ROW_NUMBER() OVER (ORDER BY started_at) - Surrogate Key (PK)
fact_trips	ride_id	VARCHAR	Fact	N/A	citibike_dwh	staging_citibike_trips	ride_id	VARCHAR	Direct mapping - Primary Key (Natural Key)
fact_trips	date_key	DATE	Fact	N/A	citibike_dwh	staging_citibike_trips	started_at	TIMESTAMP	CAST(started_at AS TIMESTAMP)::DATE - FK to dim_date.date_key
fact_trips	start_station_id	VARCHAR	Fact	N/A	citibike_dwh	staging_citibike_trips	start_station_id	VARCHAR	Direct mapping - FK to dim_station.station_id
fact_trips	end_station_id	VARCHAR	Fact	N/A	citibike_dwh	staging_citibike_trips	end_station_id	VARCHAR	Direct mapping - FK to dim_station.station_id
fact_trips	bike_type	VARCHAR	Fact	N/A	citibike_dwh	staging_citibike_trips	rideable_type	VARCHAR	rideable_type AS bike_type - FK to dim_bike.bike_type
fact_trips	user_type	VARCHAR	Fact	N/A	citibike_dwh	staging_citibike_trips	member_casual	VARCHAR	member_casual AS user_type - Degenerate Dimension (embedded)
fact_trips	duration_minutes	NUMERIC(10,2)	Fact	N/A	citibike_dwh	staging_citibike_trips	started_at, ended_at	TIMESTAMP	ROUND((EXTRACT(EPOCH FROM (ended_at - started_at)) / 60)::NUMERIC, 2)
dim_station	sation_sk	INTEGER	Dimension	1	citibike_dwh	staging_citibike_trips	-	-	ROW_NUMBER() OVER (ORDER BY station_id) - Surrogate Key (PK)
dim_station	station_id	VARCHAR	Dimension	1	citibike_dwh	staging_citibike_trips	start_station_id, end_station_id	VARCHAR	UNION of start/end stations, GROUP BY station_id - Natural Key
dim_station	station_name	VARCHAR	Dimension	1	citibike_dwh	staging_citibike_trips	start_station_name, end_station_name	VARCHAR	MAX(station_name) - handles GPS variations
dim_station	lat	NUMERIC	Dimension	1	citibike_dwh	staging_citibike_trips	start_lat, end_lat	NUMERIC	MAX(lat) - stabilizes GPS coordinates
dim_station	lng	NUMERIC	Dimension	1	citibike_dwh	staging_citibike_trips	start_lng, end_lng	NUMERIC	MAX(lng) - stabilizes GPS coordinates
dim_date	date_sk	INTEGER	Dimension	1	citibike_dwh	staging_citibike_trips	started_at, ended_at	TIMESTAMP	TO_CHAR(date_val, 'YYYYMMDD')::INTEGER - Smart Surrogate Key (PK, z.B. 20240115)
dim_date	date_key	DATE	Dimension	1	citibike_dwh	staging_citibike_trips	started_at, ended_at	TIMESTAMP	CAST(started_at AS TIMESTAMP)::DATE UNION CAST(ended_at AS TIMESTAMP)::DATE
dim_date	year	INTEGER	Dimension	1	citibike_dwh	staging_citibike_trips	started_at, ended_at	TIMESTAMP	EXTRACT(YEAR FROM date_val)
dim_date	month	INTEGER	Dimension	1	citibike_dwh	staging_citibike_trips	started_at, ended_at	TIMESTAMP	EXTRACT(MONTH FROM date_val)
dim_date	day	INTEGER	Dimension	1	citibike_dwh	staging_citibike_trips	started_at, ended_at	TIMESTAMP	EXTRACT(DAY FROM date_val)
dim_date	day_of_week	VARCHAR	Dimension	1	citibike_dwh	staging_citibike_trips	started_at, ended_at	TIMESTAMP	TRIM(TO_CHAR(date_val, 'Day'))
dim_bike	bike_sk	INTEGER	Dimension	1	citibike_dwh	staging_citibike_trips	-	-	ROW_NUMBER() OVER (ORDER BY bike_type) - Surrogate Key (PK)
dim_bike	bike_type	VARCHAR	Dimension	1	citibike_dwh	staging_citibike_trips	rideable_type	VARCHAR	SELECT DISTINCT rideable_type AS bike_type
dim_weather	weather_sk	INTEGER	Dimension	1	citibike_dwh	staging_weather_historical	-	-	ROW_NUMBER() OVER (ORDER BY date_key) - Surrogate Key (PK)
dim_weather	date_key	DATE	Dimension	1	citibike_dwh	staging_weather_historical	date_key	VARCHAR/DATE	CAST(date_key AS DATE) - Natural Key
dim_weather	temp_max_celsius	NUMERIC	Dimension	1	citibike_dwh	staging_weather_historical	temp_max_celsius	NUMERIC	Direct mapping from Open-Meteo API (temperature_2m_max)
dim_weather	temp_min_celsius	NUMERIC	Dimension	1	citibike_dwh	staging_weather_historical	temp_min_celsius	NUMERIC	Direct mapping from Open-Meteo API (temperature_2m_min)
dim_weather	precipitation_mm	NUMERIC	Dimension	1	citibike_dwh	staging_weather_historical	precipitation_mm	NUMERIC	Direct mapping from Open-Meteo API (precipitation_sum)
dim_weather	weather_condition	VARCHAR	Dimension	1	citibike_dwh	staging_weather_historical	precipitation_mm	NUMERIC	CASE WHEN precipitation_mm = 0 THEN '1_Trocken' WHEN precipitation_mm > 0 AND precipitation_mm <= 5 THEN '2_Leichter Regen (0-5mm)' ELSE '3_Starker Regen (>5mm)' END
dim_user_type	user_sk	INTEGER	Dimension	1	citibike_dwh	staging_citibike_trips	-	-	ROW_NUMBER() OVER (ORDER BY user_type) - Surrogate Key (PK)
dim_user_type	user_type	VARCHAR	Dimension	1	citibike_dwh	staging_citibike_trips	member_casual	VARCHAR	SELECT DISTINCT member_casual AS user_type - Natural Key

Abbildung 4 - Data Map

3.2 Flow Diagram

Der ETL-Prozess integriert CitiBike-Fahrtdaten aus CSV-Dateien mit historischen Wetterdaten aus der Open-Meteo API. In der Extract-Phase werden beide Quellen mit Python eingelesen. In der Transform-Phase werden Datumsformate vereinheitlicht, irrelevante Attribute entfernt, fehlende Werte geprüft, Dubletten gelöscht und ungültige Werte wie negative Fahrtdauern bereinigt. Anschließend werden die Wetterdaten über einen gemeinsamen date_key mit den Fahrtdaten verknüpft. In der Load-Phase werden die bereinigten und integrierten Daten in ein PostgreSQL Data Warehouse geladen, das als Star Schema mit Fact- und Dimensionstabellen modelliert ist. Die Umsetzung erfolgt mit Python, pandas, requests, SQLAlchemy und PostgreSQL. Zur Sicherstellung der Datenqualität werden Plausibilitätsprüfungen, Standardisierungen und Integritätskontrollen durchgeführt.

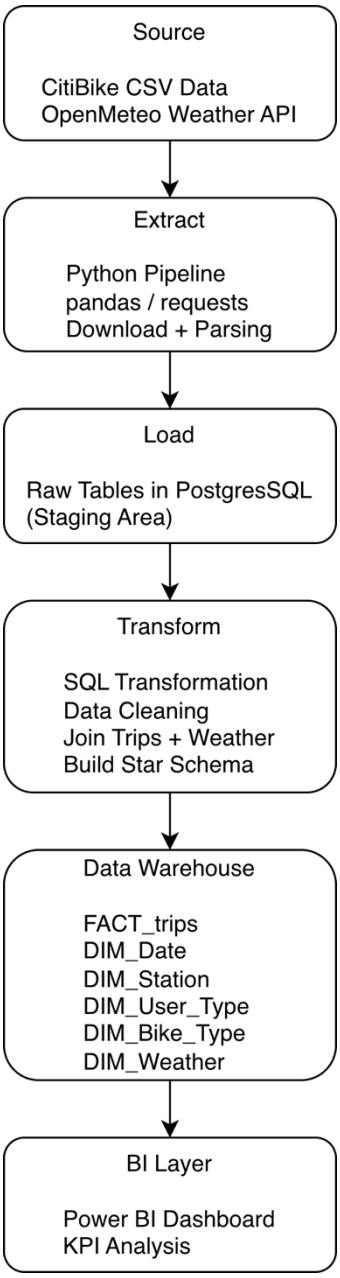

Abbildung 5 - Data Flow

4 ETL implementation

Github: https://github.com/floholzer/Citibike_Project

4.1 Beschreibug des ETL-Prozesses

4.1.1 Extract-Phase

In der Extract-Phase werden Daten aus zwei unterschiedlichen Quellen geladen:
Die CitiBike-Fahrtdaten werden aus CSV-Dateien extrahiert. Zusätzlich werden historische Wetterdaten über die API von Open-Meteo abgerufen.

Umsetzung mittels:
- Python (run_pipeline.py)
- pandas (read_csv)
- requests (API Calls)

4.1.2 Transform-Phase

Die Rohdaten werden vor dem Laden bereinigt und vorbereitet:
- Umwandlung von Datumsfeldern (datetime)
- Berechnung / Prüfung der Fahrtdauer
- Entfernen von Duplikaten
- Behandlung fehlender Werte
- Erstellung eines date_key

Nach dem Laden werden SQL-Skripte ausgeführt:
sql_transformations/ 01_create_dim_station.sql
02_create_dim_date.sql
03_create_dim_bike.sql
04_create_fact_trips.sql
05_create_dim_weather.sql
06_create_dim_user_type.sql
Diese Skripte:
- erstellen Dimensionstabellen
- bauen die Faktentabelle
- verknüpfen Daten (JOINs)
- strukturieren das Star Schema

4.1.3 Load-Phase

Nach der Vorverarbeitung werden die Daten in PostgreSQL geladen.

Zielsystem: PostgreSQL (Docker)
Struktur: Star Schema

Faktentabelle: fact_trips
Dimensionstabellen: dim_station, dim_date, dim_bike, dim_user_type, dim_weather,
Umsetzung: Python (SQLAlchemy / DB-Verbindung), SQL (CREATE TABLE + INSERT)

4.2 Ergebnis

4.2.1 Pipeline-Ausführung

„start_pipeline.bat“ ausführen:

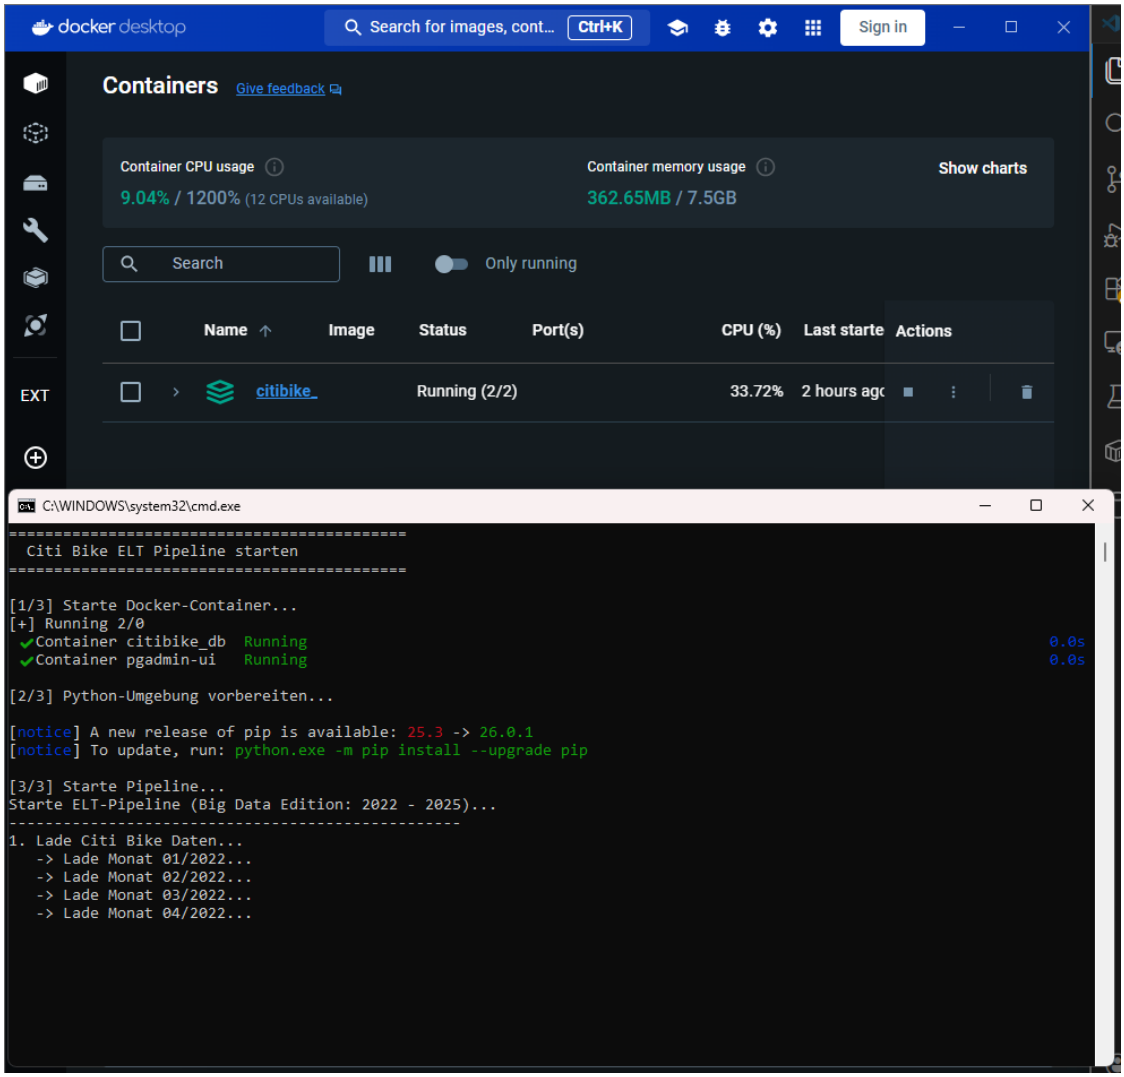

Abbildung 6: Starten der Pipeline

4.2.2 SQL-Transformation

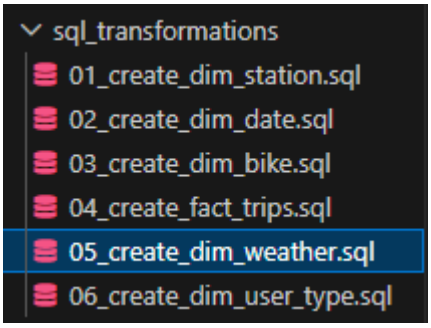

Abbildung 7: SQL-Transformationsskripte

sql_transformations > 05_create_dim_weather.sql

Run on active connection | Select block

```sql
DROP TABLE IF EXISTS dim_weather;
-- Erstelle die Wetter-Dimension
CREATE TABLE dim_weather AS
WITH cleaned_weather AS (
    SELECT
        CAST(date_key AS DATE) AS date_key,
        temp_max_celsius,
        temp_min_celsius,
        precipitation_mm,
        CASE
            WHEN precipitation_mm = 0 THEN '1_Trocken'
            WHEN precipitation_mm > 0 AND precipitation_mm <= 5 THEN '2_Leichter Regen (0-5mm)'
            ELSE '3_Starker Regen (>5mm)'
        END AS weather_condition
    FROM staging_weather_historical
)
SELECT
    ROW_NUMBER() OVER (ORDER BY date_key) AS weather_sk, -- Surrogate Key
    TO_CHAR(date_key, 'YYYYMMDD')::INTEGER AS date_sk,   -- Smart Key (für Zuordnung zur Date Dim)
    date_key,
    temp_max_celsius,
    temp_min_celsius,
    precipitation_mm,
    weather_condition
FROM cleaned_weather;
```

Abbildung 8: Beispiel eines SQL-Transformationsskripts "05_create_dim_weather.sql"

4.2.3 Nutzung der Daten in PowerBI

Daten abrufen:

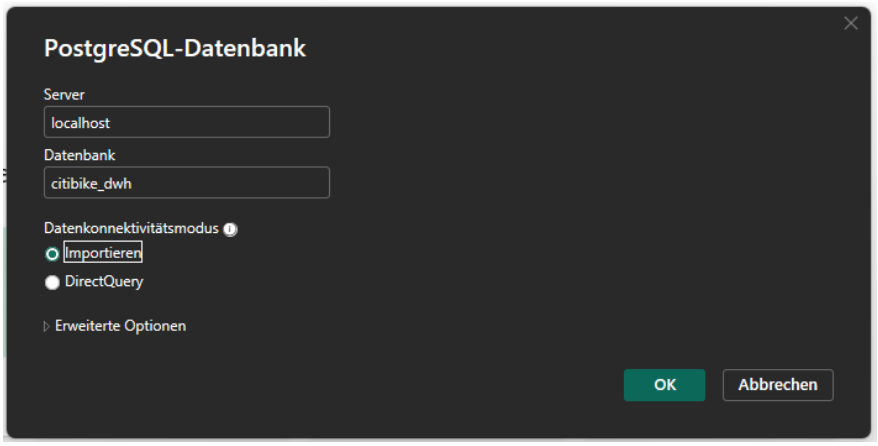

Abbildung 9: Daten abrufen aus PostgreSQL-Datenbank

Tabellen laden:

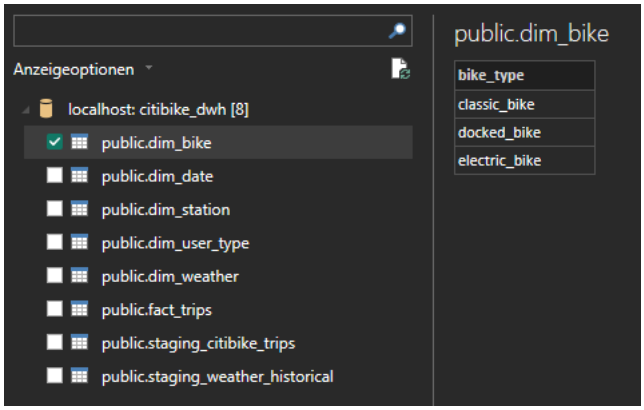

Abbildung 10: Tabellen laden - dim_bike

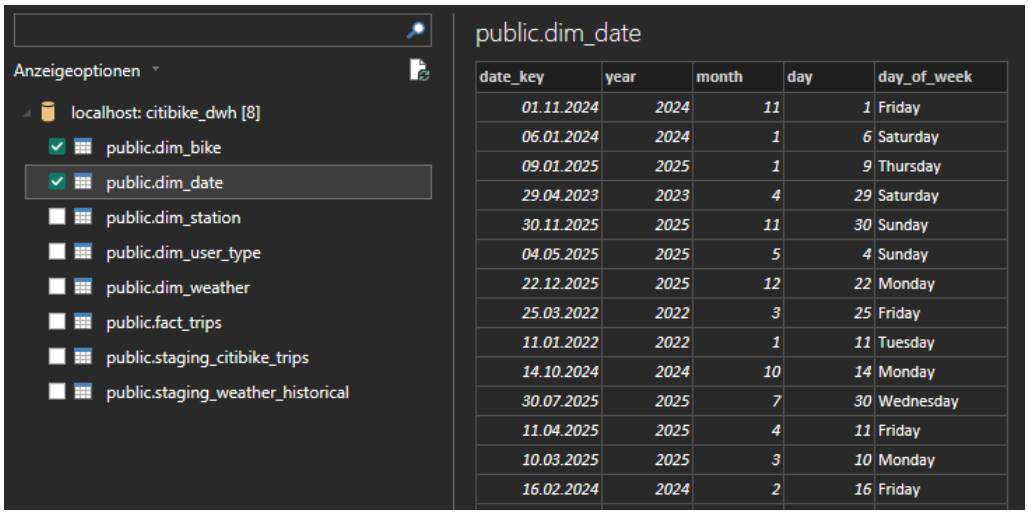

date_key	year	month	day	day_of_week
01.11.2024	2024	11	1	Friday
06.01.2024	2024	1	6	Saturday
09.01.2025	2025	1	9	Thursday
29.04.2023	2023	4	29	Saturday
30.11.2025	2025	11	30	Sunday
04.05.2025	2025	5	4	Sunday
22.12.2025	2025	12	22	Monday
25.03.2022	2022	3	25	Friday
11.01.2022	2022	1	11	Tuesday
14.10.2024	2024	10	14	Monday
30.07.2025	2025	7	30	Wednesday
11.04.2025	2025	4	11	Friday
10.03.2025	2025	3	10	Monday
16.02.2024	2024	2	16	Friday

Abbildung 11: Tabellen laden - dim_date

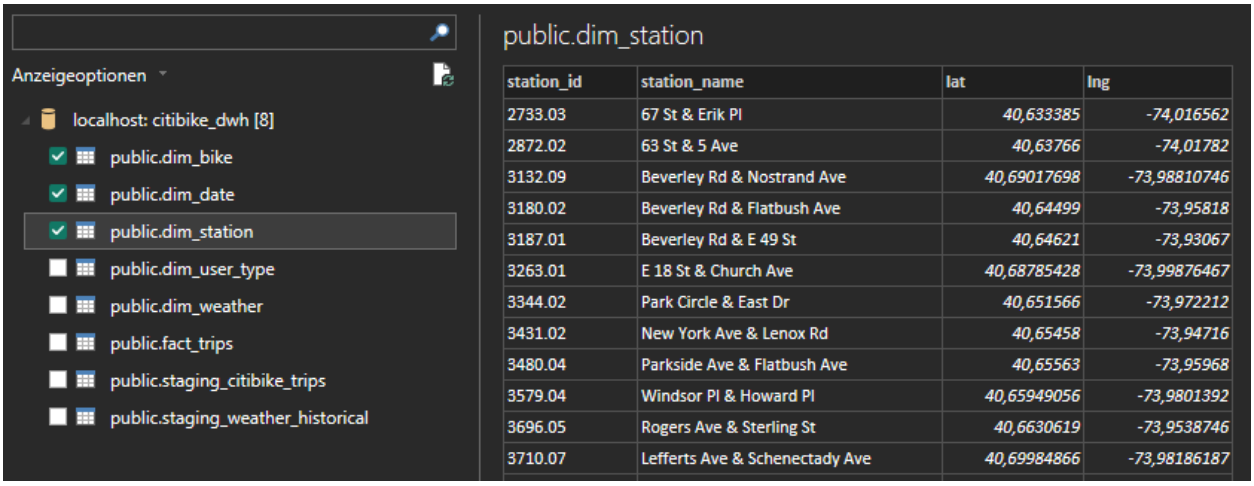

station_id	station_name	lat	lng
2733.03	67 St & Erik Pl	40,633385	-74,016562
2872.02	63 St & 5 Ave	40,63766	-74,01782
3132.09	Beverley Rd & Nostrand Ave	40,69017698	-73,98810746
3180.02	Beverley Rd & Flatbush Ave	40,64499	-73,95818
3187.01	Beverley Rd & E 49 St	40,64621	-73,93067
3263.01	E 18 St & Church Ave	40,68785428	-73,99876467
3344.02	Park Circle & East Dr	40,651566	-73,972212
3431.02	New York Ave & Lenox Rd	40,65458	-73,94716
3480.04	Parkside Ave & Flatbush Ave	40,65563	-73,95968
3579.04	Windsor Pl & Howard Pl	40,65949056	-73,9801392
3696.05	Rogers Ave & Sterling St	40,6630619	-73,9538746
3710.07	Lefferts Ave & Schenectady Ave	40,69984866	-73,98186187

Abbildung 12: Tabellen laden - dim_station

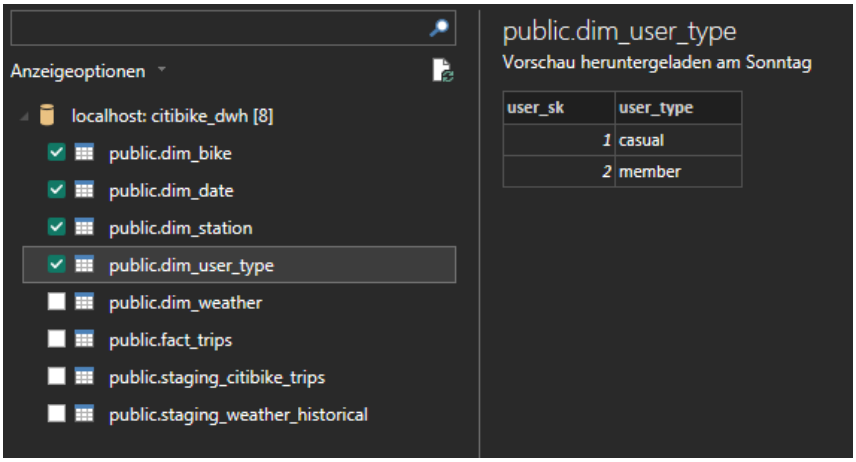

user_sk	user_type
1	casual
2	member

Abbildung 13: Tabellen laden - dim_user_type

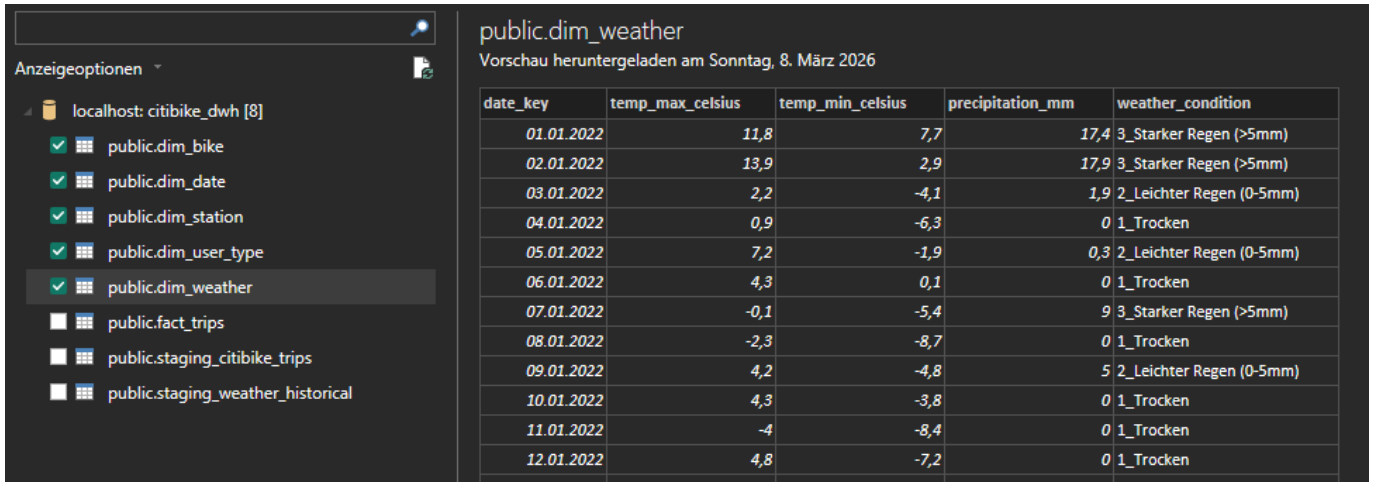

date_key	temp_max_celsius	temp_min_celsius	precipitation_mm	weather_condition
01.01.2022	11,8	7,7	17,4	3_Starker Regen (>5mm)
02.01.2022	13,9	2,9	17,9	3_Starker Regen (>5mm)
03.01.2022	2,2	-4,1	1,9	2_Leichter Regen (0-5mm)
04.01.2022	0,9	-6,3	0	1_Trocken
05.01.2022	7,2	-1,9	0,3	2_Leichter Regen (0-5mm)
06.01.2022	4,3	0,1	0	1_Trocken
07.01.2022	-0,1	-5,4	9	3_Starker Regen (>5mm)
08.01.2022	-2,3	-8,7	0	1_Trocken
09.01.2022	4,2	-4,8	5	2_Leichter Regen (0-5mm)
10.01.2022	4,3	-3,8	0	1_Trocken
11.01.2022	-4	-8,4	0	1_Trocken
12.01.2022	4,8	-7,2	0	1_Trocken

Abbildung 14: Tabellen laden - dim_weather

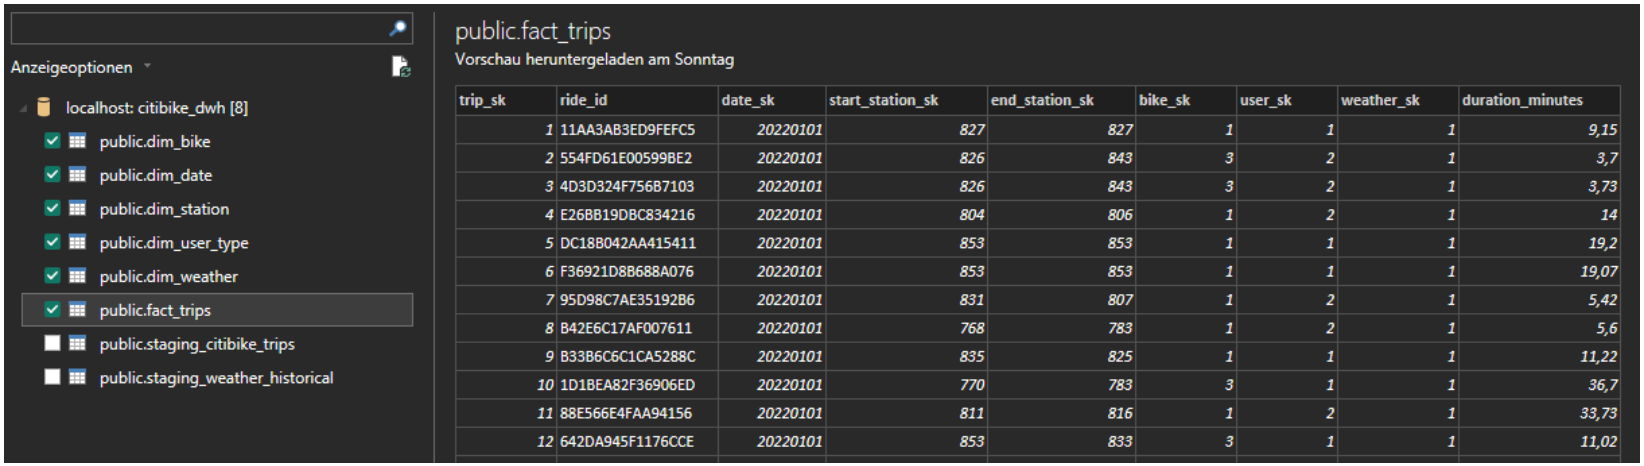

trip_sk	ride_id	date_sk	start_station_sk	end_station_sk	bike_sk	user_sk	weather_sk	duration_minutes
1	11AA3AB3ED9FEFC5	20220101	827	827	1	1	1	9,15
2	554FD61E00599BE2	20220101	826	843	3	2	1	3,7
3	4D3D324F756B7103	20220101	826	843	3	2	1	3,73
4	E26BB19DBC834216	20220101	804	806	1	2	1	14
5	DC18B042AA415411	20220101	853	853	1	1	1	19,2
6	F36921D8B688A076	20220101	853	853	1	1	1	19,07
7	95D98C7AE35192B6	20220101	831	807	1	2	1	5,42
8	B42E6C17AF007611	20220101	768	783	1	2	1	5,6
9	B33B6C6C1CA5288C	20220101	835	825	1	1	1	11,22
10	1D1BEA82F36906ED	20220101	770	783	3	1	1	36,7
11	88E566E4FAA94156	20220101	811	816	1	2	1	33,73
12	642DA945F1176CCE	20220101	853	833	3	1	1	11,02

Abbildung 15: Tabellen laden - fact_trips

Modellansicht:

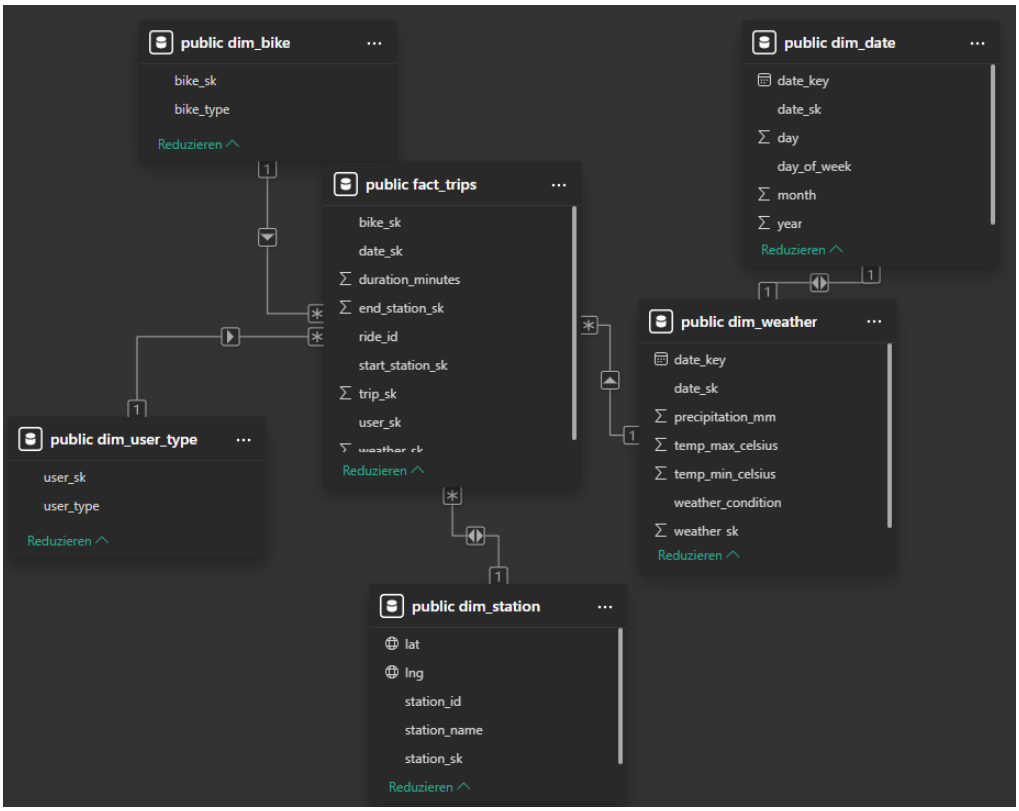

Abbildung 16: Modellansicht PowerBI

5 Data modelling and BI

5.1 Data modelling

Insert a screenshot of data model modelled in PowerBI
Important: include screenshots for the configuration of all dimensions, including the created hierarchies if applicable.

6 BI Implementation

Present your BI implementation with a few screenshots, list your questions from section 2 and the answers to those questions. The screenshots should show that drill-down is supported.

Abbildung 1 - DFM 5
Abbildung 2 – Star Schema 6
Abbildung 3 – Star Schema (PBI) 6
Abbildung 4 - Data Map 7
Abbildung 5 - Data Flow 8
Abbildung 6: Starten der Pipeline 10
Abbildung 7: SQL-Transformationsskripte 10
Abbildung 8: Beispiel eines SQL-Transformationsskripts "05_create_dim_weather.sql" 11
Abbildung 9: Daten abrufen aus PostgreSQL-Datenbank 11
Abbildung 10: Tabellen laden - dim_bike 11
Abbildung 11: Tabellen laden - dim_date 12
Abbildung 12: Tabellen laden - dim_station 12
Abbildung 13: Tabellen laden - dim_user_type 12
Abbildung 14: Tabellen laden - dim_weather 13
Abbildung 15: Tabellen laden - fact_trips 13
Abbildung 16: Modellansicht PowerBI 14